旁白提词稿 v2

对齐「无配音 · 无字幕」画面版：全片 4:16（256 秒） | 1920×1080 / 30fps

每段一页，念的时候只看当下那一页。时刻按正常语速 ≈ 4.5 字/秒估算，仅供参考；念得顺比卡秒重要。

红线：不出现学校名 / 校徽 / 导师姓名；不提无人机；不说「已经在全校部署」。数字不许念错：0.929 / 0.936 / 0.933 / 2.93M / 199 / 92.4% / 400 / 640。

段 1　0:00 起（画面 0:00–0:30）

画面：失败一页 0:00–0:06 → 漏检图×4 0:06–0:14 → 框尺寸直方图 0:14–0:22 → 漏检图×4 0:22–0:30

配音：丙　|　本段 146 字

▶ 0:00（念约 8 秒）

先看这间教室。后排这些座位上的头，在画面里大概只有十几个像素。

▶ 0:06（念约 8 秒）

整个数据集里，92.4% 的目标框宽度不到 32 像素，是典型的小目标场景。

▶ 0:14（念约 8 秒）

官方 YOLOv8n 在这张图上基本是空的——后排这些头，它一个都没框住。

▶ 0:22（念约 9 秒）

这不是模型不够大，而是它看这张图的方式有问题。我们接下来要做的，就是把这个地方改掉。

本段念完约 0:31，画面到 0:30 —— 差 1 秒，正常。

段 2　0:31 起（画面 0:30–1:40）

画面：结构图 0:30–0:45 → 步长表 0:45–1:12 → yaml 标注 1:12–1:26 → 结构图（放大颈部）1:26–1:40

配音：丙　|　本段 299 字

▶ 0:31（念约 12 秒）

教室图像先由骨干网络提取多尺度特征，再经过颈部网络融合，最后由检测头输出边界框。改动主要发生在颈部网络。

▶ 0:42（念约 25 秒）

官方 YOLOv8n 的骨干网络已经计算出步长为 4 的 P2 特征图，颈部却没有把这一层送入检测头，最小检测步长仍是 8。教室后排大约 20 像素的人头，在步长 8 的特征图上只占一到两个单元格，所以空间分辨率不够，小目标容易漏检，边界框也不稳定。

▶ 1:07（念约 30 秒）

把 P2 接入颈部融合之后，检测头改为在四个尺度上预测。同一个目标在步长 4 的特征图上大约占五个单元格。特征图对齐以后，原来的拼接改为加权融合，各层特征与权重相乘后再相加，权重非负，并且和为 1。加权融合的 mAP50 是 0.933，只接入 P2 时是 0.936，精度没有继续提高。

本段 0:31 起（比结构图画面晚 1 秒，用来避开上一段的话尾 —— 段 1 最后一句说到 0:30.4 才结束）。念完约 1:35.5，画面到 1:40，留 4 秒收尾。这一段是乙写的稿，照念，不念代码。

段 3　1:40 起（画面 1:40–2:41）

画面：甲录屏（只留前 40 秒）1:40–2:20 → 三列对比图×3 2:20–2:41

配音：丙　｜　本段 215 字

▶ 1:40（念约 4 秒）

那改完之后效果怎么样？看这段录屏。

▶ 1:43（念约 16 秒）

同一张图、同一台机器、同样的输入尺寸：左边是官方 YOLOv8n，右边是我们接上 P2 之后的模型。左边后排的位置是空的，右边在同样的位置把框标出来了。

▶ 2:00（念约 7 秒）

这个差别不是调参调出来的，是因为模型现在能看到更细的那一层特征。

▶ 2:20（念约 21 秒）

再接上加权融合是这样：第一列官方，第二列只接 P2，第三列是完整方法。三列对比下来，P2 已经把后排这些头找回来了，加权融合在这个基础上的变化很小——这一点我们不回避，讲数字的时候会如实说。

本段念完约 2:41，正好压在画面结束点上。第 4 句开始念时，画面会切到三列对比图。

段 4　2:40 起（画面 2:41–3:38）

画面：主表 2:41–3:08 → 同一张主表放大（mAP50、参数两列）3:08–3:38

配音：丙　｜　本段 272 字

▶ 2:40（念约 11 秒）

把结果摆成一张表。验证集是完全相同的 400 张，输入尺寸都是 640，所有模型的训练轮数都是 100。

▶ 2:51（念约 15 秒）

官方 YOLOv8n 的 mAP50 是 0.929；接上 P2 之后是 0.936，提高 0.7 个百分点。而参数量不但没涨，反而从 3.0M 降到 2.93M。

▶ 3:06（念约 8 秒）

再加加权融合是 0.933，没有继续提高。这一段我们照实写，不把它当成增益。

▶ 3:14（念约 26 秒）

作为对比，YOLOv8s 的 mAP50 是 0.940，看着更高，但它要 11.13M 参数、28.4G FLOPs，大概是 P2 方案的三点八倍。我们的目标场景是算力和显存都有限的边缘设备，在这个约束下，用不到 3M 参数拿到 0.936，是更合适的选择。

本段 2:40 起（比主表画面早 1 秒，作引子），念完约 3:39.9；与下一段之间留 1.1 秒气口。

段 5　3:42 起（画面 3:38–4:16）

画面：字幕卡（参数与 FPS）3:38–3:58 → 结尾卡（远端收尾）3:58–4:16

配音：丙　｜　本段 160 字

▶ 3:42（念约 2 秒）

最后说两件事。

▶ 3:44（念约 15 秒）

这套模型只有 2.93M 参数，同样的测速口径下能跑到 199 FPS，具备放到边缘设备上的条件；但我们没在真实边缘设备上部署过，这一步不夸大。

▶ 4:02（念约 19 秒）

另外，在公开的远景数据集 TinyPerson 上我们也验证过一次，结果和官方基本持平——极端远景只靠改颈部还不够，还得用自己采集的远端画面重新标数据、微调，这一步我们没做。

本段 3:42 起。上一段（段 4）话尾到 3:40.4 才结束，这里再等 1.6 秒才开口，避免两段撞在一起；结尾卡已加长到 4:16。